GEOSCENE AI
CLASIFICACIÓN DE COBERTURAS · EUROSAT RGB

Lectura preliminar de imágenes satelitales

Una CNN propia propone una de 10 categorías, señala los casos dudosos y deja la decisión final a la persona analista.

RAMA INTEGRACION/COMPLETA | CHECKPOINT CERTIFICADO SHA-256 | 38 PRUEBAS | SIN GPU

RENDIMIENTO EN TEST

82,70 %
accuracy sobre 1.000 imágenes

82,44 % macro F1
97,50 % top-3
173 errores · 53 sin marcar

MODELO ENTREGADO

CNN 32 / 64 canales
545.098 parámetros · 2,1 MB · época 20
umbral de revisión 0,73 · sin BatchNorm

FICHA EJECUTIVA
Noviembre de 2026

API · PANEL · SWAGGER LOCALES
127.0.0.1:8000

Qué resuelve y para quién

Un equipo de análisis territorial recibe imágenes satelitales y tiene que organizarlas por tipo de superficie. Hacerlo una por una es lento y propenso a errores.

LA HERRAMIENTA

Hace una primera lectura de cada imagen, propone una categoría y marca los casos que no son claros para que el analista los revise con calma.

PARA QUIÉN

Analista de imágenes que necesita cargar una imagen, ver la categoría propuesta y confirmarla o corregirla antes de registrarla.

LO QUE NO ES

- × **No es cartografía**
  no produce mapas ni geometrías
- × **No decide por su cuenta**
  la última palabra es humana
- × **No conoce fuera de EuroSAT**
  siempre responde una de 10 clases

FLUJO DE DECISIÓN

SUGIERE	categoría + confianza + top-3
MARCA	confianza < 0,73 → revisión
DECIDE	la persona acepta o corrige

Del archivo a la decisión humana

01 **IMAGEN**
JPG o PNG
máx. 10 MB

→

02 **API**
32×32 + normalización
media y desviación

→

03 **CNN**
logits de 10 clases
545.098 parámetros

→

04 **SOFTMAX**
probabilidades
top-3

→

05 **UMBRAL**
0,73
calibrado en validación

CONFIANZA ≥ 0,73

Sugerencia directa

La interfaz muestra categoría, confianza y top-3.
La persona puede aceptarla o corregirla.

CONFIANZA < 0,73

Revisión humana

La interfaz avisa que conviene revisar.
26,9 % de las imágenes de test caen aquí.

CONTRATO ENTRE CAPAS

Streamlit solo habla HTTP con FastAPI; nunca importa el modelo.

Predicción y decisión van a outputs/predicciones.csv y outputs/decisiones.csv.
Corregir no borra lo que dijo el modelo: todo queda auditable.

El límite de subida es 10 MB, idéntico en la interfaz y en la API.

EuroSAT RGB: 27.000 imágenes, 10 clases

IMÁGENES TOTALES	CLASES	SEMILLA	RESOLUCIÓN
27.000	10	42	64×64
Sentinel-2 · 64×64 px	mismo peso en macro F1	particiones reproducibles	se reduce a 32×32



REGLAS DE LA MUESTRA

- 500 imágenes por clase para entrenar (5.000).
- 100 por clase para validación y 100 para test.
- Sin imágenes repetidas entre particiones.
- La partición se crea una vez y se versiona.

LAS 10 CLASES

01 Cultivo anual
02 Bosque
03 Vegetación herbácea
04 Autopista
05 Zona industrial
06 Pastizal
07 Cultivo permanente
08 Zona residencial
09 Río
10 Mar o lago

CNN propia, desde cero y sin pesos preentrenados

ENTRADA
RGB
3×32×32

→

BLOQUE 1
Conv 3×3 · 32
ReLU + MaxPool
32×16×16

→

BLOQUE 2
Conv 3×3 · 64
ReLU + MaxPool
64×8×8

→

FLATTEN
4096
números

→

DENSE
128
Dropout 0,3

→

SALIDA
10 logits
softmax en API

Conteo de parámetros · sin BatchNorm	
Conv 3×3 · 3 → 32	896
Conv 3×3 · 32 → 64	18.496
Dense 4096 → 128	524.416
Dense 128 → 10	1.290
TOTAL	**545.098**

VARIANTE COMPARADA · FEATURE/JOHAN

64 / 128 canales + BatchNorm2d

4.275.978 parámetros · no es el modelo versionado

La referencia entregada es 32 / 64, sin BatchNorm.

POR QUÉ ESTA RED

- Dos bloques alcanzan para texturas de 32×32.
- Cada capa se puede explicar y auditar.
- Entrena y evalúa en CPU, sin GPU.
- La variante con BatchNorm es solo comparación.

Forward, backward y selección por validación

HIPERPARÁMETROS EFECTIVOS

OPTIMIZADOR	Adam
LEARNING RATE	0,001
WEIGHT DECAY	0,0001
LOTE	64
PÉRDIDA	CrossEntropyLoss
ÉPOCAS	20 fijas
SCHEDULER	ninguno
AUMENTO	giros H y V

CICLO DE UNA ÉPOCA

01 forward → logits [B, 10]

02 loss → CrossEntropy

03 zero_grad

04 backward → ∂L/∂W

05 optimizer.step → Adam

VALIDACIÓN DESPUÉS DE CADA ÉPOCA

modelo.eval() + torch.no_grad() → solo forward
Se guarda el checkpoint de la mejor accuracy de validación.
Dropout 0,3 activo solo en entrenamiento.

ÉPOCA ELEGIDA

20

de 20 posibles

VALIDACIÓN

80,7 %

accuracy

CHECKPOINT

2,1 MB

SHA-256 certificado

PRUEBAS

38

pytest · 0 fallos

Resultados en test: 1.000 imágenes, una sola vez

ACCURACY TOP-1
82,70 %
827 aciertos de 1.000

MACRO F1
82,44 %
10 clases con el mismo peso

TOP-3
97,50 %
top-5 99,60 %

ERRORES
173
53 sin marcar

DESAGREGACIÓN

PÉRDIDA (CROSSENTROPY)
0,5055

PRECISIÓN MACRO
82,71 %

RECALL MACRO
82,70 %

F1 PONDERADO
82,44 %

CONFIANZA MEDIA
82,53 %

LECTURA

El modelo acierta 8 de cada 10 imágenes y casi siempre pone la clase correcta entre sus tres primeras opciones. El test se usó una sola vez, con la época y el umbral ya elegidos en validación.

El umbral separa lo seguro de lo dudoso

UMBRAL CALIBRADO

0,73

confianza < 0,73 → revisión

Elegido en validación como el valor más bajo con ≥ 90 % de precisión en las no marcadas.

COBERTURA	MARCADAS	ACC. NO MARCADAS	ACC. MARCADAS
73,1 %	26,9 %	92,75 %	55,39 %
sin revisión	1 de cada 3,7	cuando confía	cuando duda

COMPORTAMIENTO



La regla reduce el riesgo, pero no lo elimina.

LÍMITE DE LA REGLA

53 de 173 errores

tenían confianza ≥ 0,73 y no se habrían marcado (30,6 % de todos los errores).

Una confianza alta no garantiza acierto.

Subir el umbral reduce la cobertura y aumenta la fiabilidad; bajarlo hace lo contrario.

Resultados por clase en test

CLASE	PRECISIÓN	RECALL	F1
Bosque	0,941	0,960	**0,951**
Zona industrial	0,929	0,920	**0,925**
Mar o lago	0,938	0,900	**0,918**
Zona residencial	0,902	0,920	**0,911**
Pastizal	0,870	0,870	**0,870**
Cultivo anual	0,837	0,870	**0,853**
Río	0,752	0,790	**0,771**
Vegetación herbácea	0,677	0,860	**0,758**
Cultivo permanente	0,736	0,670	**0,702**
Autopista	0,689	0,510	**0,586**

F1 POR CLASE



Bosque e industria son las más fáciles. Autopista es la más débil: encuentra 51 de 100.
Vegetación herbácea tiene recall alto (0,86) pero precisión baja (0,677): atrae confusiones.

Dónde se equivoca el modelo



ACIERTOS POR CLASE

Cultivo anual	87	Pastizal	87
Bosque	96	Cultivo perm.	67
Veg. herbácea	86	Residencial	92
Autopista	51	Río	79
Industrial	92	Mar o lago	90

AUTOPISTA · 51 ACIERTOS, 49 ERRORES

Vegetación herbácea	13
Río	12
Cultivo permanente	10
Cultivo anual	7
Industrial	3
Residencial	3
Pastizal	1

Franja delgada: a 32×32 ocupa pocos píxeles.

Los tres fallos de mayor confianza

01
Río → Autopista
99,79 %
NO MARCADO
Forma de franja y agua grisácea: a 32×32 domina la geometría.

supera el umbral 0,73

02
Río → Zona industrial
97,84 %
NO MARCADO
El patrón del cauce se confunde con superficies construidas.

supera el umbral 0,73

03
Pastizal → Veg. herbácea
97,29 %
NO MARCADO
Clases vecinas: la diferencia de textura casi desaparece.

supera el umbral 0,73

UN CASO QUE SÍ ATRAPÓ EL UMBRAL
Zona residencial → Cultivo permanente
30,05 %
MARCADO PARA REVISIÓN
La persona ve el aviso, revisa el top-3 y corrige a residencial.

LECTURA
Los tres errores de mayor confianza superaron el umbral y no se marcaron.

53 de 173 errores (30,6 %) están en esa zona. Por eso el aviso de alcance y la revisión humana siguen siendo obligatorios.

El modelo no sabe decir «no lo conozco»

BLANCA
→ Mar o lago
91,78 %
confianza alta · no se marcó

NEGRA
→ Veg. herbácea
99,98 %
confianza alta · no se marcó

RUIDO
→ Zona residencial
100,00 %
confianza alta · no se marcó

QUÉ SIGNIFICA

El modelo solo conoce las 10 clases de EuroSAT. Cualquier imagen recibe una de ellas, aunque no tenga nada que ver.

La confianza solo tiene sentido dentro de ese dominio: fuera de él puede ser altísima y estar completamente equivocada.

CONSECUENCIA PARA EL USO

El aviso de alcance es obligatorio:
«Es una clasificación visual preliminar y no debe usarse sola para decisiones de ordenamiento territorial o ambientales.»

La interfaz y /alcance lo muestran siempre.

MEDIDO CON EL CHECKPOINT ENTREGADO

Tres imágenes sintéticas fuera de dominio: blanca, negra y ruido uniforme.
Ninguna quedó marcada para revisión por el umbral.

Qué puede salir mal y cómo se controla

RIESGO

Usar una lectura preliminar como evaluación territorial concluyente.

El modelo puede acertar el 82,7 % de las veces y aun así equivocarse con más de 97 % de confianza en una imagen concreta.

53 errores del test no se habrían marcado.

MITIGACIÓN

- ✓ La herramienta solo sugiere; la persona decide.
- ✓ Umbral 0,73: lo dudoso pasa a revisión.
- ✓ Top-3 visible para comparar alternativas.
- ✓ Aviso de alcance siempre en pantalla.
- ✓ Predicción y decisión registradas por separado.

DECISIONES TÉCNICAS

CNN PROPIA | SIN PREENTRENADOS | SIN GPU | MISMA TRANSFORMACIÓN TRAIN/APP | API SEPARADA DE LA INTERFAZ | REGISTROS SEPARADOS | TEST USADO UNA VEZ

La época y el umbral se eligieron con validación; el test no se usó para ajustar.

Cómo verificarlo y qué sigue

CERTIFICACIÓN

SHA-256 DEL CHECKPOINT

e073084a…d58de571

545.098 parámetros · época 20 · umbral 0,73
2,1 MB · Torch 2.15 · Python 3.15

38 pruebas · 0 fallos
0,21 ms por imagen · 4.819 img/s en CPU
petición HTTP completa: 2–4 ms en local

CÓMO CORRERLO

```
1  python -m venv .venv && activar
2  pip install -r requirements.txt
3  uvicorn api.main:app --port 8000
4  streamlit run interfaz/app.py
```

Panel	/panel	Swagger	/docs
Salud	/health	Reporte	/reporte

Windows: py -3 y .venv\Scripts\activate
macOS/Linux: python3 y source .venv/bin/activate

SIGUIENTE VERSIÓN

→ Entrenar a 64×64 (resolución original).

→ Probar ResNet-18 con fine-tuning.

→ Añadir clase de rechazo o detección OOD.

→ Comparar formalmente la variante con BatchNorm.

FUENTES

EuroSAT · Helber et al. (2019)
IEEE JSTARS · vía torchvision

PyTorch · torchvision · scikit-learn · NumPy
Pillow · Matplotlib · FastAPI · Uvicorn
Streamlit · Swagger UI · pytest